

Algorithmique Probabiliste

Philippe Duchon

LaBRI - ENSEIRB-Matméca - Université de Bordeaux

2014-15

Le sujet

- Utilisation *explicite* de tirages aléatoires dans des algorithmes

Le sujet



- ▶ Utilisation *explicite* de tirages aléatoires dans des algorithmes
- ▶ Analyse des complexités des algorithmes

Le sujet

- ▶ Utilisation *explicite* de tirages aléatoires dans des algorithmes
- ▶ Analyse des complexités des algorithmes
- ▶ Quelques principes de conception d'algorithmes

Bibliographie expresse

- ▶ R. Motwani, P. Raghavan, *Randomized Algorithms*, Cambridge University Press, 1995.
- ▶ M. Mitzenmacher, E. Upfal, *Probability and Computing : Randomized Algorithms and Probabilistic Analysis* - Cambridge University Press, 2002.



Algorithme “classique”

- ▶ Un algorithme “classique” est **totalemment déterministe**

Algorithme “classique”

- ▶ Un algorithme “classique” est **totalelement déterministe**
- ▶ Étant donnés un algorithme A et une donnée x ,

Algorithme “classique”

- ▶ Un algorithme “classique” est **totale**ment **déterministe**
- ▶ Étant donné un algorithme A et une donnée x ,
 - ▶ le résultat $A(x)$ est entièrement déterminé ;

Algorithme “classique”

- ▶ Un algorithme “classique” est **totalelement déterministe**
- ▶ Étant donnés un algorithme A et une donnée x ,
 - ▶ le résultat $A(x)$ est entièrement déterminé ;
 - ▶ la séquence de calculs aussi ;

Algorithme “classique”

- ▶ Un algorithme “classique” est **totalelement déterministe**
- ▶ Étant donnés un algorithme A et une donnée x ,
 - ▶ le résultat $A(x)$ est entièrement déterminé ;
 - ▶ la séquence de calculs aussi ;
 - ▶ en particulier, *il n’y a aucun intérêt à relancer le même calcul.*

Algorithme “probabiliste”

(Synonyme : algorithme randomisé)

- ▶ L'algorithme “tire à pile ou face” **et peut agir différemment en fonction du résultat**

Algorithme “probabiliste”

(Synonyme : algorithme randomisé)

- ▶ L'algorithme “tire à pile ou face” **et peut agir différemment en fonction du résultat**
- ▶ En conséquence, pour un algorithme et une donnée fixés,

Algorithme “probabiliste”

(Synonyme : algorithme randomisé)

- ▶ L'algorithme “tire à pile ou face” **et peut agir différemment en fonction du résultat**
- ▶ En conséquence, pour un algorithme et une donnée fixés,
 - ▶ le résultat $A(x)$ est une *variable aléatoire*

Algorithme “probabiliste”

(Synonyme : algorithme randomisé)

- ▶ L'algorithme “tire à pile ou face” **et peut agir différemment en fonction du résultat**
- ▶ En conséquence, pour un algorithme et une donnée fixés,
 - ▶ le résultat $A(x)$ est une *variable aléatoire*
 - ▶ de même que la séquence de calculs, et toutes les grandeurs associées (temps, mémoire, etc)

Algorithme “probabiliste”

(Synonyme : algorithme randomisé)

- ▶ L'algorithme “tire à pile ou face” **et peut agir différemment en fonction du résultat**
- ▶ En conséquence, pour un algorithme et une donnée fixés,
 - ▶ le résultat $A(x)$ est une *variable aléatoire*
 - ▶ de même que la séquence de calculs, et toutes les grandeurs associées (temps, mémoire, etc)
 - ▶ en particulier, *il peut être intéressant de lancer plusieurs fois le même algorithme sur les mêmes données (et de “prendre le meilleur résultat”)*

Ça pose des questions...

- ▶ Comment **décrire** des algorithmes probabilistes ? quel est le modèle ?

Ça pose des questions...

- ▶ Comment **décrire** des algorithmes probabilistes ? quel est le modèle ?
- ▶ Comment **raisonner** sur de tels algorithmes ?

Ça pose des questions...

- ▶ Comment **décrire** des algorithmes probabilistes ? quel est le modèle ?
- ▶ Comment **raisonner** sur de tels algorithmes ?
- ▶ C'est quoi, un “bon” algorithme probabiliste ?

Ça pose des questions...

- ▶ Comment **décrire** des algorithmes probabilistes ? quel est le modèle ?
- ▶ Comment **raisonner** sur de tels algorithmes ?
- ▶ C'est quoi, un “bon” algorithme probabiliste ?
- ▶ Quelles sont les “bonnes” grandeurs à évaluer ?

Ça pose des questions...

- ▶ Comment **décrire** des algorithmes probabilistes ? quel est le modèle ?
- ▶ Comment **raisonner** sur de tels algorithmes ?
- ▶ C'est quoi, un “bon” algorithme probabiliste ?
- ▶ Quelles sont les “bonnes” grandeurs à évaluer ?
- ▶ (par l'exemple)

Ça pose des questions...

- ▶ Comment **décrire** des algorithmes probabilistes ? quel est le modèle ?
- ▶ Comment **raisonner** sur de tels algorithmes ?
- ▶ C'est quoi, un “bon” algorithme probabiliste ?
- ▶ Quelles sont les “bonnes” grandeurs à évaluer ?
- ▶ (par l'exemple)
- ▶ (ce qui implique de refaire un peu de probabilités)

Un exemple frappant : égalité de deux chaînes

- ▶ Deux machines M et M' détiennent chacune une chaîne binaire, s et s' , de même longueur n ; on souhaite déterminer si oui ou non on a $s = s'$

Un exemple frappant : égalité de deux chaînes

- ▶ Deux machines M et M' détiennent chacune une chaîne binaire, s et s' , de même longueur n ; on souhaite déterminer si oui ou non on a $s = s'$
- ▶ On s'intéresse à la *complexité de communication* : le temps de calcul n'importe pas, seule compte la longueur des messages envoyés

Un exemple frappant : égalité de deux chaînes

- ▶ Deux machines M et M' détiennent chacune une chaîne binaire, s et s' , de même longueur n ; on souhaite déterminer si oui ou non on a $s = s'$
- ▶ On s'intéresse à la *complexité de communication* : le temps de calcul n'importe pas, seule compte la longueur des messages envoyés
- ▶ Pour simplifier, on suppose un protocole à 1 message :
 - ▶ M calcule : $m = f(s)$, et envoie m à M'
 - ▶ M' calcule : $r = g(m, s')$
 - ▶ le résultat est *correct* si r vaut $[s=s']$
 - ▶ la *complexité de communication* du protocole est la longueur du message envoyé, $C = \ell(m)$

Solution déterministe

- ▶ Un protocole (un choix de fonctions f et g) est correct si, pour tout n , et pour toutes chaînes s, s' de longueur n , le résultat r obtenu est correct

Solution déterministe

- ▶ Un protocole (un choix de fonctions f et g) est correct si, pour tout n , et pour toutes chaînes s, s' de longueur n , le résultat r obtenu est correct
- ▶ **Théorème** : pour tout protocole correct, pour tout n , il existe une instance (s, s') pour laquelle M envoie au moins n bits.

Solution déterministe

- ▶ Un protocole (un choix de fonctions f et g) est correct si, pour tout n , et pour toutes chaînes s, s' de longueur n , le résultat r obtenu est correct
- ▶ **Théorème** : pour tout protocole correct, pour tout n , il existe une instance (s, s') pour laquelle M envoie au moins n bits.
- ▶ **Preuve ?**

Solution déterministe

- ▶ Un protocole (un choix de fonctions f et g) est correct si, pour tout n , et pour toutes chaînes s, s' de longueur n , le résultat r obtenu est correct
- ▶ **Théorème** : pour tout protocole correct, pour tout n , il existe une instance (s, s') pour laquelle M envoie au moins n bits.
- ▶ **Preuve ?**
- ▶ En d'autres termes : en déterministe, *il n'y a pas de solution intrinsèquement plus intelligente que de demander à M d'envoyer sa chaîne s tout entière à M'*

Solution probabiliste : description

(On interprète les chaînes s et s' comme de grands entiers, de l'ordre de 2^n)

- ▶ M **choisit aléatoirement et uniformément** un nombre entier p , premier, compris entre $n^2/2$ et n^2
- ▶ M calcule $x = s \bmod p$, et envoie $m = (x, p)$ à M'
- ▶ M' calcule $x' = s' \bmod p$, et répond $x'=x$

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**
- ▶ **On peut parfois avoir un résultat incorrect** : cela arrive exactement si $s \neq s'$, mais que le nombre entier p choisi est un **diviseur** de $|s - s'|$

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**
- ▶ **On peut parfois avoir un résultat incorrect** : cela arrive exactement si $s \neq s'$, mais que le nombre entier p choisi est un **diviseur** de $|s - s'|$
- ▶ Si $s = s'$, la *probabilité de résultat incorrect* est d'exactement 0 ;

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**
- ▶ **On peut parfois avoir un résultat incorrect** : cela arrive exactement si $s \neq s'$, mais que le nombre entier p choisi est un **diviseur** de $|s - s'|$
- ▶ Si $s = s'$, la *probabilité de résultat incorrect* est d'exactement 0 ;
- ▶ Si $s \neq s'$, la *probabilité de résultat incorrect* est exactement :
$$p_{s,s'} = \frac{\text{nombre de diviseurs premiers, entre } n^2/2 \text{ et } n^2, \text{ de } |s - s'|}{\text{nombre d'entiers premiers entre } n^2/2 \text{ et } n^2}$$

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**
- ▶ **On peut parfois avoir un résultat incorrect** : cela arrive exactement si $s \neq s'$, mais que le nombre entier p choisi est un **diviseur** de $|s - s'|$
- ▶ Si $s = s'$, la *probabilité de résultat incorrect* est d'exactement 0 ;
- ▶ Si $s \neq s'$, la *probabilité de résultat incorrect* est exactement :
$$p_{s,s'} = \frac{\text{nombre de diviseurs premiers, entre } n^2/2 \text{ et } n^2, \text{ de } |s - s'|}{\text{nombre d'entiers premiers entre } n^2/2 \text{ et } n^2}$$
- ▶ Le numérateur est trivialement inférieur à n (et même à $n/2 \log_2(n)$)

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**
- ▶ **On peut parfois avoir un résultat incorrect** : cela arrive exactement si $s \neq s'$, mais que le nombre entier p choisi est un **diviseur** de $|s - s'|$
- ▶ Si $s = s'$, la *probabilité de résultat incorrect* est d'exactement 0 ;
- ▶ Si $s \neq s'$, la *probabilité de résultat incorrect* est exactement :
$$p_{s,s'} = \frac{\text{nombre de diviseurs premiers, entre } n^2/2 \text{ et } n^2, \text{ de } |s - s'|}{\text{nombre d'entiers premiers entre } n^2/2 \text{ et } n^2}$$
- ▶ Le numérateur est trivialement inférieur à n (et même à $n/2 \log_2(n)$)
- ▶ Le dénominateur est (d'après le théorème des nombres premiers) de l'ordre de $\frac{n^2}{4 \ln(n)}$

Solution probabiliste : analyse

- ▶ x et p sont des entiers au plus égaux à n^2 , donc de longueur au plus $2 \log_2(n)$: **la complexité de communication est de $4 \log_2(n)$**
- ▶ **On peut parfois avoir un résultat incorrect** : cela arrive exactement si $s \neq s'$, mais que le nombre entier p choisi est un **diviseur** de $|s - s'|$
- ▶ Si $s = s'$, la *probabilité de résultat incorrect* est d'exactement 0 ;
- ▶ Si $s \neq s'$, la *probabilité de résultat incorrect* est exactement :
$$p_{s,s'} = \frac{\text{nombre de diviseurs premiers, entre } n^2/2 \text{ et } n^2, \text{ de } |s - s'|}{\text{nombre d'entiers premiers entre } n^2/2 \text{ et } n^2}$$
- ▶ Le numérateur est trivialement inférieur à n (et même à $n/2 \log_2(n)$)
- ▶ Le dénominateur est (d'après le théorème des nombres premiers) de l'ordre de $\frac{n^2}{4 \ln(n)}$
- ▶ **Conclusion** : le protocole probabiliste a, *pour toute instance* (s, s') , une probabilité inférieure à $2 \ln(2)/n$ de se tromper.

Comparons. . .

On prend le cas $n = 10^9 \sim 2^{30}$: un gigabit

- ▶ **Déterministe** : on est absolument certain du résultat ; M doit envoyer 1 gigabit à M' .

Comparons. . .

On prend le cas $n = 10^9 \sim 2^{30}$: un gigabit

- ▶ **Déterministe** : on est absolument certain du résultat ; M doit envoyer 1 gigabit à M' .
- ▶ **Probabiliste** : M envoie 120 bits à M' ; en contrepartie, on accepte une probabilité d'erreur d'environ 1.4×10^{-9} (une chance sur 700 millions ; soit la probabilité d'être choisi si une personne résidant en Europe est choisie au hasard)

Comparons...

On prend le cas $n = 10^9 \sim 2^{30}$: un gigabit

- ▶ **Déterministe** : on est absolument certain du résultat ; M doit envoyer 1 gigabit à M' .
- ▶ **Probabiliste** : M envoie 120 bits à M' ; en contrepartie, on accepte une probabilité d'erreur d'environ 1.4×10^{-9} (une chance sur 700 millions ; soit la probabilité d'être choisi si une personne résidant en Europe est choisie au hasard)
- ▶ **En répétant deux fois le protocole probabiliste** : M envoie 240 bits à M' , la probabilité d'erreur tombe à 2×10^{-18} (probabilité que le choix de **deux** personnes au hasard en Europe, vous désigne, vous **et** votre voisin de gauche)

Comparons...

On prend le cas $n = 10^9 \sim 2^{30}$: un gigabit

- ▶ **Déterministe** : on est absolument certain du résultat ; M doit envoyer 1 gigabit à M' .
- ▶ **Probabiliste** : M envoie 120 bits à M' ; en contrepartie, on accepte une probabilité d'erreur d'environ 1.4×10^{-9} (une chance sur 700 millions ; soit la probabilité d'être choisi si une personne résidant en Europe est choisie au hasard)
- ▶ **En répétant deux fois le protocole probabiliste** : M envoie 240 bits à M' , la probabilité d'erreur tombe à 2×10^{-18} (probabilité que le choix de **deux** personnes au hasard en Europe, vous désigne, vous **et** votre voisin de gauche)
- ▶ (ce n'est rien d'autre qu'un schéma de hachage, explicitement aléatoire ; la propriété importante étant que, la fonction de hachage étant aléatoire, **on ne peut pas choisir deux chaînes différentes en sachant qu'elles ont la même valeur de hachage**)

L'exemple de **QuickSort**

Pour trier un tableau de n valeurs :

- ▶ Si $n \leq 1$, il est déjà trié
- ▶ Sinon :
 - ▶ choisir un *pivot* (premier élément du tableau) x
 - ▶ comparer x à chaque autre élément, et réordonner le tableau en “les plus petits que x ”, puis x , puis “les plus grands que x ”
 - ▶ Trier récursivement “les plus petits que x ” et “les plus grands que x ” avec **QuickSort**

QuickSort en Python

```
def Partitionne(L,a,b,k):  
    p = L[k]  
    Echange(L,k,b)  
    st = a  
    for i in range(a,b):  
        if L[i]<p:  
            Echange(L,i,st)  
            st = st+1  
    Echange(L,st,b)  
    return(st)  
  
def QuickSortRec(L,a,b):  
    if (a<b):  
        k=Partitionne(L,a,b,a)  
        QuickSortRec(L,a,k-1)  
        QuickSortRec(L,k+1,b)
```

“Analyse” de QuickSort

- ▶ On regarde le **nombre de comparaisons de clés**

“Analyse” de QuickSort

- ▶ On regarde le **nombre de comparaisons de clés**
- ▶ “En moyenne” (si **le tableau initial est dans un ordre aléatoire uniforme**), on fait $2n \ln(n) + O(n)$ comparaisons

“Analyse” de QuickSort

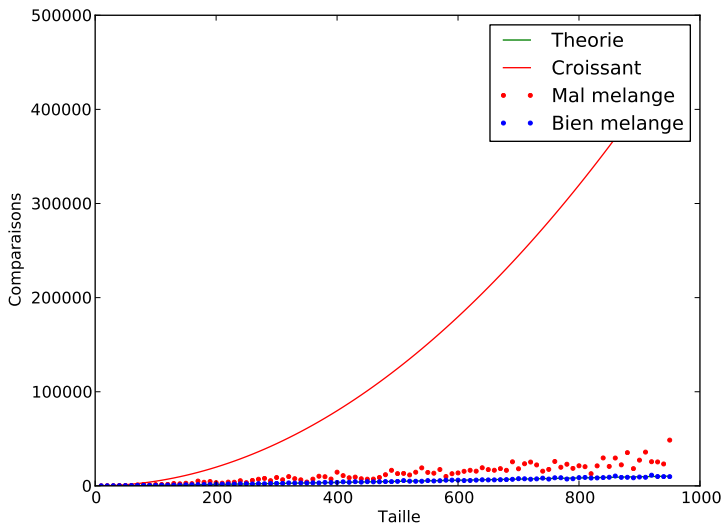
- ▶ On regarde le **nombre de comparaisons de clés**
- ▶ “En moyenne” (si **le tableau initial est dans un ordre aléatoire uniforme**), on fait $2n \ln(n) + O(n)$ comparaisons
- ▶ Mais le cas le pire est quadratique

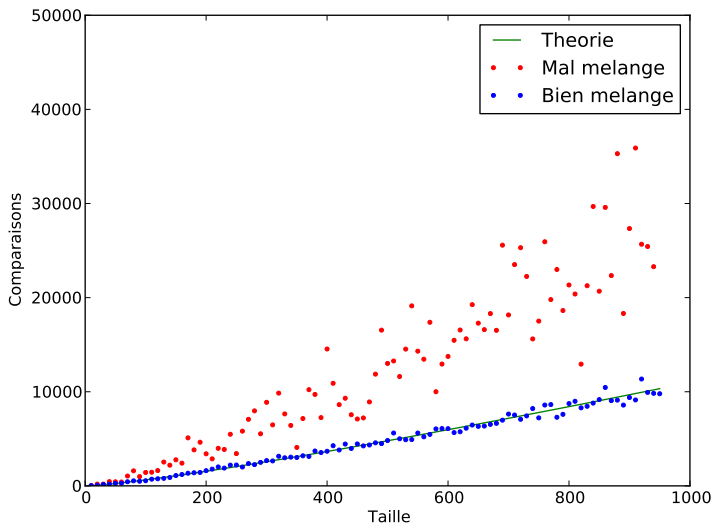
“Analyse” de QuickSort

- ▶ On regarde le **nombre de comparaisons de clés**
- ▶ “En moyenne” (si **le tableau initial est dans un ordre aléatoire uniforme**), on fait $2n \ln(n) + O(n)$ comparaisons
- ▶ Mais le cas le pire est quadratique
- ▶ **La mauvaise nouvelle** : un tableau **déjà trié** (ou “presque” déjà trié) est trié par **QuickSort** en temps quadratique

Quelques expériences

- ▶ Le code Python présenté (ou presque)
- ▶ On compte exactement les comparaisons
- ▶ Trois jeux de tests :
 - ▶ Liste triée par ordre croissant
 - ▶ Liste dans un ordre aléatoire
 - ▶ Liste croissante, “mal” mélangée ($n/10$ échanges de paires prises au hasard)





Interprétons

- ▶ Sur des listes aléatoires, l'algorithme a vraiment l'air de se comporter souvent en $\Theta(n \ln(n))$

Interprétons

- ▶ Sur des listes aléatoires, l'algorithme a vraiment l'air de se comporter souvent en $\Theta(n \ln(n))$
- ▶ Sur des listes croissantes, il est catastrophique

Interprétons

- ▶ Sur des listes aléatoires, l'algorithme a vraiment l'air de se comporter souvent en $\Theta(n \ln(n))$
- ▶ Sur des listes croissantes, il est catastrophique
- ▶ Sur des listes “un peu mal mélangées”, les performances se dégradent assez vite, et semblent assez aléatoires (grosse incertitude)

Interprétons

- ▶ Sur des listes aléatoires, l'algorithme a vraiment l'air de se comporter souvent en $\Theta(n \ln(n))$
- ▶ Sur des listes croissantes, il est catastrophique
- ▶ Sur des listes “un peu mal mélangées”, les performances se dégradent assez vite, et semblent assez aléatoires (grosse incertitude)
- ▶ **Malheureusement, on ne peut pas faire confiance à l'utilisateur de l'algorithme pour ne nous faire trier que des listes aléatoires**

Et si...

- ▶ Idée toute bête : *et si au lieu de choisir un pivot déterministe, on le choisissait au hasard dans le tableau ?*

Et si...

- ▶ Idée toute bête : *et si au lieu de choisir un pivot déterministe, on le choisissait au hasard dans le tableau ?*
- ▶ On obtient une **version randomisée** de l'algorithme : à chaque exécution, on peut avoir un comportement différent

Et si...

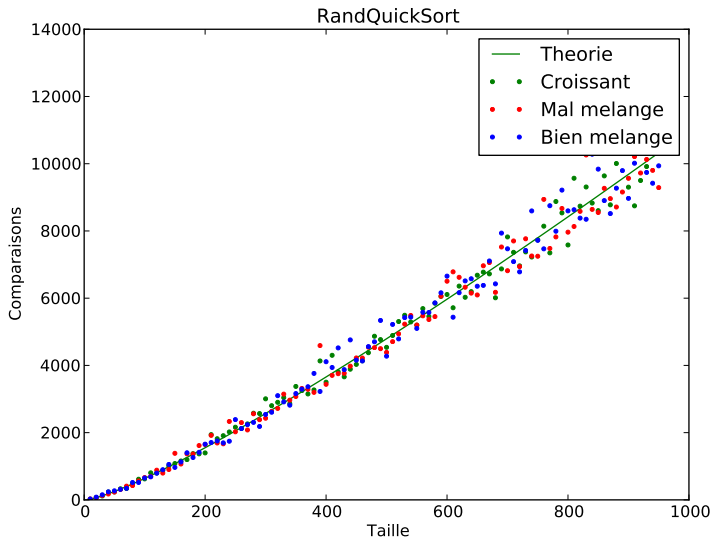
- ▶ Idée toute bête : *et si au lieu de choisir un pivot déterministe, on le choisissait au hasard dans le tableau ?*
- ▶ On obtient une **version randomisée** de l'algorithme : à chaque exécution, on peut avoir un comportement différent
- ▶ (Le résultat, lui, n'est pas aléatoire : on trie toujours dans l'ordre croissant)

Et si...

- ▶ Idée toute bête : *et si au lieu de choisir un pivot déterministe, on le choisissait au hasard dans le tableau ?*
- ▶ On obtient une **version randomisée** de l'algorithme : à chaque exécution, on peut avoir un comportement différent
- ▶ (Le résultat, lui, n'est pas aléatoire : on trie toujours dans l'ordre croissant)
- ▶ Quelques lignes de code à changer

RandQuickSort en Python

```
def RandQuickSortRec(L,a,b):  
    if (a<b):  
        k=Partitionne(L,a,b,random.randint(a,b))  
        RandQuickSortRec(L,a,k-1)  
        RandQuickSortRec(L,k+1,b)  
  
def RandQuickSort(L):  
    RandQuickSortRec(L,0,len(L)-1)
```



Ré-intreprétons...

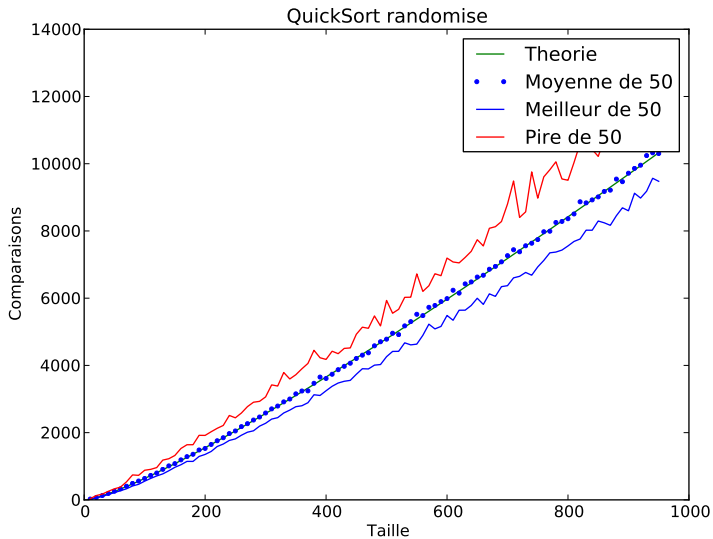
- ▶ **RandQuickSort** n'a pas l'air très sensible (statistiquement) au caractère plus ou moins bien mélangé de la liste de départ

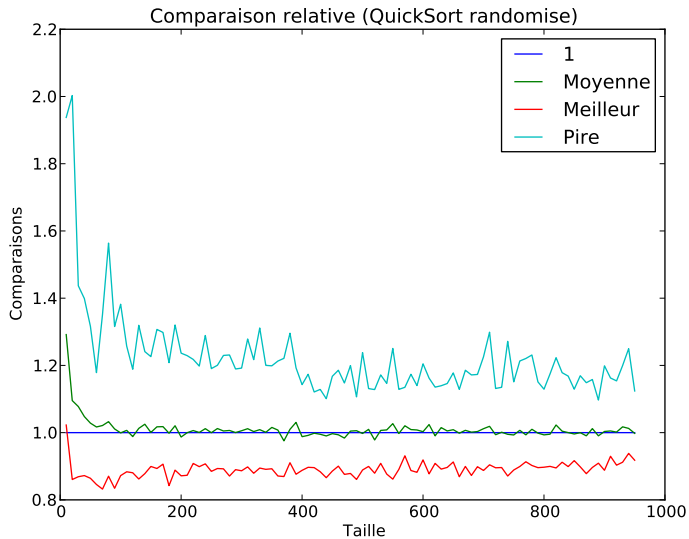
Ré-interprétons...

- ▶ **RandQuickSort** n'a pas l'air très sensible (statistiquement) au caractère plus ou moins bien mélangé de la liste de départ
- ▶ Il a l'air de *toujours* se comporter comme **QuickSort** sur des listes aléatoires

Ré-intreprétons...

- ▶ **RandQuickSort** n'a pas l'air très sensible (statistiquement) au caractère plus ou moins bien mélangé de la liste de départ
- ▶ Il a l'air de *toujours* se comporter comme **QuickSort** sur des listes aléatoires
- ▶ Les variations par rapport à la moyenne semblent assez faibles





Et maintenant ?

- ▶ On va *prouver* ce qu'on vient d'observer
- ▶ Mais on a besoin de préciser ce qu'on suppose vrai des tirages aléatoires

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- ▶ nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)
- ▶ faire en sorte que le résultat de **chaque appel** soit **indépendant de tous ceux qui l'ont précédé**

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- ▶ nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)
- ▶ faire en sorte que le résultat de **chaque appel** soit **indépendant de tous ceux qui l'ont précédé**

Variantes :

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- ▶ nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)
- ▶ faire en sorte que le résultat de **chaque appel** soit **indépendant de tous ceux qui l'ont précédé**

Variantes :

- ▶ `flip()` : équivalent à `randint(0,1)` (“pile ou face” avec une pièce équilibrée)

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- ▶ nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)
- ▶ faire en sorte que le résultat de **chaque appel** soit **indépendant de tous ceux qui l'ont précédé**

Variantes :

- ▶ `flip()` : équivalent à `randint(0,1)` (“pile ou face” avec une pièce équilibrée)
- ▶ `random()` : renvoie un nombre réel uniforme sur $[0, 1]$

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- ▶ nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)
- ▶ faire en sorte que le résultat de **chaque appel** soit **indépendant de tous ceux qui l'ont précédé**

Variantes :

- ▶ `flip()` : équivalent à `randint(0,1)` (“pile ou face” avec une pièce équilibrée)
- ▶ `random()` : renvoie un nombre réel uniforme sur $[0, 1]$
- ▶ `Bernoulli(p)` : renvoie 1 avec probabilité p , 0 avec probabilité $1 - p$ (pour $0 < p < 1$)

Générateur aléatoire

La fonction `randint(a,b)` de Python (module `random`) est censée

- ▶ nous renvoyer un nombre entier aléatoire compris entre a et b (inclus), **uniforme** (chaque entier de $[[a, b]]$ a probabilité $1/(b - a + 1)$)
- ▶ faire en sorte que le résultat de **chaque appel** soit **indépendant de tous ceux qui l'ont précédé**

Variantes :

- ▶ `flip()` : équivalent à `randint(0,1)` (“pile ou face” avec une pièce équilibrée)
- ▶ `random()` : renvoie un nombre réel uniforme sur $[0, 1]$
- ▶ `Bernoulli(p)` : renvoie 1 avec probabilité p , 0 avec probabilité $1 - p$ (pour $0 < p < 1$)
- ▶ **toujours** en supposant que les appels sont **indépendants**

Analyse de [Rand]QuickSort

Théorème

Soit $n \geq 1$, $\sigma \in S_n$ une permutation quelconque de $[[1, n]]$, et soit

- ▶ QS_n , la variable aléatoire qui décrit le nombre de comparaisons de clés dans une exécution de l'algorithme déterministe **QuickSort** sur un *tableau de n valeurs distinctes, rangées initialement dans un ordre aléatoire uniforme*;
- ▶ $RQS_n(\sigma)$, la variable aléatoire qui décrit le nombre de comparaisons de clés dans une exécution de l'algorithme randomisé **RandQuickSort** sur un *tableau de n valeurs distinctes, rangées initialement selon l'ordre σ* .

Alors QS_n et $RQS_n(\sigma)$ ont la **même loi** : pour tout k ,

$$\mathbb{P}(QS_n = k) = \mathbb{P}(RQS_n(\sigma) = k).$$

Analyse de [Rand]QuickSort

Théorème

Soit $n \geq 1$, $\sigma \in S_n$ une permutation quelconque de $[[1, n]]$, et soit

- ▶ QS_n , la variable aléatoire qui décrit le nombre de comparaisons de clés dans une exécution de l'algorithme déterministe **QuickSort** sur un *tableau de n valeurs distinctes, rangées initialement dans un ordre aléatoire uniforme* ;
- ▶ $RQS_n(\sigma)$, la variable aléatoire qui décrit le nombre de comparaisons de clés dans une exécution de l'algorithme randomisé **RandQuickSort** sur un *tableau de n valeurs distinctes, rangées initialement selon l'ordre σ* .

Alors QS_n et $RQS_n(\sigma)$ ont la **même loi** : pour tout k ,

$$\mathbb{P}(QS_n = k) = \mathbb{P}(RQS_n(\sigma) = k).$$

Corollaire 1 : même espérance, même variance. . .

Analyse de [Rand]QuickSort

Théorème

Soit $n \geq 1$, $\sigma \in S_n$ une permutation quelconque de $[[1, n]]$, et soit

- ▶ QS_n , la variable aléatoire qui décrit le nombre de comparaisons de clés dans une exécution de l'algorithme déterministe **QuickSort** sur un *tableau de n valeurs distinctes, rangées initialement dans un ordre aléatoire uniforme* ;
- ▶ $RQS_n(\sigma)$, la variable aléatoire qui décrit le nombre de comparaisons de clés dans une exécution de l'algorithme randomisé **RandQuickSort** sur un *tableau de n valeurs distinctes, rangées initialement selon l'ordre σ* .

Alors QS_n et $RQS_n(\sigma)$ ont la **même loi** : pour tout k ,

$$\mathbb{P}(QS_n = k) = \mathbb{P}(RQS_n(\sigma) = k).$$

Corollaire 1 : même espérance, même variance. . .

Corollaire 2 : pour **RandQuickSort**, il n'y a pas de tableau plus mauvais qu'un autre